

PROJETO DE INTELIGÊNCIA ARTIFICIAL

Triagem Inteligente de Pronto-Socorro

Equipe: Diogo Novaes, Heitor Airola, Pedro Maia, Miguel Melo e Luan Cavalcanti

1. Definição do Problema e Objetivos

Contexto e Problema

UPAs e prontos-socorros brasileiros operam frequentemente acima da capacidade, e a triagem de pacientes ainda é feita de forma manual por enfermeiros, com base em protocolos como o Protocolo de Manchester. Esse processo é suscetível a erros humanos causados por sobrecarga, fadiga e subjetividade clínica, o que pode resultar em dois cenários críticos:

- Pacientes graves sendo subclassificados — risco direto de morte por atraso no atendimento.
- Pacientes leves ocupando recursos prioritários — travamento da fila e desperdício de insumos.

O desafio principal é a ineficiência e o risco clínico da triagem manual em ambientes de alta demanda, onde cada segundo conta e a margem para erro é nula.

Objetivo da IA

O modelo deve classificar automaticamente o nível de prioridade de atendimento de um paciente no momento da sua chegada ao pronto-socorro, com base em dados clínicos coletados na recepção. A saída do modelo é uma das quatro categorias do Protocolo de Manchester simplificado:

Cor	Prioridade	Tempo-alvo de atendimento
Verde	Não urgente	Pode aguardar
Amarelo	Urgente	Até 60 minutos
Laranja	Muito urgente	Até 10 minutos
Vermelho	Emergência	Atendimento imediato

Métricas de Sucesso

- Métrica técnica principal:** Macro F1-Score acima de 0,80 — escolhido no lugar de acurácia simples porque as classes são desbalanceadas (emergências são raras, mas críticas).
- Métrica de segurança clínica:** Recall da classe Vermelho acima de 95% — neste contexto clínico, falsos negativos representam um risco crítico à segurança do paciente.
- Métrica operacional:** Tempo de inferência abaixo de 2 segundos por paciente, viabilizando uso em tempo real na recepção.

2. Estratégia de Dados

Fontes de Dados

- **DATASUS / SIHSUS:** Registros de internações e atendimentos hospitalares do SUS, com CID-10, idade, procedimentos e desfechos.
- **Kaggle — Emergency CAS Dataset:** Dataset público com registros de triagem em pronto-socorro contendo sinais vitais e classificação de prioridade.
- **Kaggle — Patient Triage Dataset:** Dados tabulares com sintomas, pressão arterial, temperatura, frequência cardíaca e nível de triagem já rotulado.
- **Dados sintéticos (se necessário):** Geração controlada via SMOTE para balancear a classe Vermelho, que tende a ser sub-representada nos registros históricos.

Variáveis de Entrada (Features)

Feature	Tipo	Exemplo
Idade	Numérico	67
Pressão arterial sistólica	Numérico	180 mmHg
Temperatura corporal	Numérico	39,2 °C
Frequência cardíaca	Numérico	112 bpm
Saturação de oxigênio (SpO2)	Numérico	91%
Sintoma principal relatado	Categórico / Texto	"dor no peito"
Nível de consciência	Categórico	Alerta / Confuso / Inconsciente
Histórico de comorbidades	Booleano	Diabetes, HAS, etc.

Volume e Qualidade

Espera-se trabalhar com entre 10.000 e 100.000 registros históricos de atendimento. Os principais desafios de qualidade identificados são:

- Valores nulos em sinais vitais (pacientes que chegam sem medição prévia no campo).
- Desbalanceamento severo de classes (emergências representam menos de 5% dos casos).
- Inconsistências nos registros de sintomas em texto livre, com variações ortográficas e abreviações.

O pré-processamento envolverá imputação por mediana para variáveis numéricas, encoding para variáveis categóricas e, opcionalmente, um modelo de NLP leve para vetorizar os sintomas relatados em texto.

3. Abordagem Técnica e Modelagem

Tipo de Aprendizado

Aprendizado **supervisionado de classificação multiclasse** (4 classes: verde, amarelo, laranja, vermelho). Os dados históricos de triagem já possuem rótulos definidos por profissionais de saúde, o que viabiliza essa abordagem diretamente sem necessidade de anotação manual adicional.

Modelo Baseline

O ponto de partida será uma Regressão Logística Multinomial, treinada apenas com as variáveis numéricas (idade, pressão, temperatura, SpO2, FC). É interpretável, rápida de treinar e estabelece um piso de desempenho honesto para comparação com modelos mais complexos.

Critério de avaliação do baseline: se atingir $F1 > 0,70$, o problema é bem estruturado e os dados são suficientemente informativos. Se ficar abaixo, isso indica que as features de sintomas em texto são indispensáveis para discriminar as classes.

Evolução da Modelagem

Etapa	Modelo	Justificativa
1 — Baseline	Regressão Logística Multinomial	Interpretável, sem hiperparâmetros complexos, piso de referência
2 — Intermediário	Random Forest	Robusto a outliers, lida bem com dados mistos, oferece importância de features
3 — Avançado	XGBoost / LightGBM	Melhor desempenho em dados tabulares desbalanceados, suporte nativo a classes minoritárias
4 — Extensão NLP	TF-IDF + XGBoost ou BERTimbau	Para incorporar os sintomas em texto livre com semântica em português

Bibliotecas e Stack Técnico

Etapa	Biblioteca / Ferramenta
Manipulação de dados	pandas, numpy
Pré-processamento	scikit-learn (Pipeline, ColumnTransformer)
Balanceamento de classes	imbalanced-learn (SMOTE)
Modelagem	scikit-learn, xgboost, lightgbm
Avaliação	scikit-learn (classification_report, confusion matrix)
NLP (extensão opcional)	transformers (BERTimbau), sentence-transformers
Visualização	matplotlib, seaborn